

基于联邦集成算法对多源数据安全性的研究*

罗长银^{1,2,3}, 陈学斌^{1,2,3}, 刘 洋^{1,2,3}, 张淑芬^{1,2,3}

(1. 华北理工大学理学院, 河北 唐山 063210; 2. 河北省数据科学与应用重点实验室, 河北 唐山 063210;
3. 唐山市数据科学重点实验室, 河北 唐山 063210)

摘 要: 联邦学习是隐私保护领域关注的热点内容, 存在难以集中本地模型参数与因梯度更新造成数据泄露的问题。提出了一种联邦集成算法, 使用 256 B 的密钥将不同类型的初始化模型传输至各数据源并训练, 使用不同的集成算法来整合本地模型参数, 使数据与模型的安全性得到很大提升。仿真结果表明, 对于中小数据集而言, 使用 Adaboost 集成算法得到的模型准确率达到 92.505%, 标准差约为 8.6×10^{-8} , 对于大数据集而言, 采用 stacking 集成算法得到的模型的准确率达到 92.495%, 标准差约为 8.85×10^{-8} , 与传统整合多方数据集集中训练模型的方法相比, 在保证准确率的同时兼顾了数据与模型的安全性。

关键词: 联邦学习; 集成算法; 隐私保护; 联邦集成算法

中图分类号: TP391

文献标志码: A

doi: 10.3969/j.issn.1007-130X.2021.08.007

A federated ensemble algorithm for multi-source data security

LUO Chang-yin^{1,2,3}, CHEN Xue-bin^{1,2,3}, LIU Yang^{1,2,3}, ZHANG Shu-fen^{1,2,3}

(1. College of Science, North China University of Science and Technology, Tangshan 063210;
2. Hebei Key Laboratory of Data Science and Application, Tangshan 063210;
3. Tangshan Key Laboratory of Data Science, Tangshan 063210, China)

Abstract: Federated learning is a hot topic in the field of privacy protection, and it has a problem that it is difficult to concentrate local model parameters and data leakage due to gradient updates. This paper proposes a federated ensemble algorithm. The proposal uses a 256-byte key to transfer different types of initialization models to various data sources and do the training, and uses different ensemble algorithms to integrate local model parameters to ensure the security of the data and the model, thus greatly improving the security of data and model. Simulation results show that, for small and medium data sets, the accuracy of the model obtained by the adaboost integration algorithm reaches 92.505%, and the variance is about 8.6×10^{-8} . For large data sets, the accuracy of the model obtained by the stacking ensemble algorithm reaches 92.495%, and the variance is about 8.85×10^{-8} . Compared with the traditional method of training the model with integrated data, the proposal ensures the accuracy while taking into account the data and the model safety.

Key words: federated learning; ensemble algorithm; privacy protection; federated ensemble algorithm

1 引言

近年来,随着数据挖掘等技术的快速发展,隐

私数据安全保护显得尤为重要,且传统的隐私保护技术并不能满足要求,2016 年谷歌首次推出“联邦学习”概念,受到社会各界以及专家学者的广泛关注^[1]。联邦学习的训练数据来源于各个数据源上

* 收稿日期:2020-06-15;修回日期:2020-09-09
基金项目:国家自然科学基金(61572170,61170254);唐山市科技项目(18120203A)
通信地址:063210 河北省唐山市华北理工大学理学院
Address:College of Science, North China University of Science and Technology, Tangshan 063210, Hebei, P. R. China

的本地数据,不需要收集、存储数据到云端和整合多方数据,这种方法大大减少了敏感信息泄露的风险^[2]。但是,因联邦学习的训练数据来源于不同数据源,训练数据并不能满足独立分布和训练数量一致这2个能影响联邦模型的条件^[3]。若数据源的训练数据分布不同,那么整合多方子模型成为巨大的难题^[4]。文献^[5]使用 logistic 回归模型作为初始模型对各个数据源的数据进行训练,采用神经网络来整合多方子模型,但神经网络模型一般表现为非凸函数,很难使参数平均化后的模型损失函数达到最优。文献^[6]针对独立同分布和非独立同分布的数据进行了研究,发现当训练数据是非独立分布时,其训练的全局模型精度不能满足预期要求。针对上述问题,本文提出了联邦集成算法,其所做的贡献如下所示:

(1)通过 RSA 加密算法产生的公钥来加密由 hash 算法计算出的数据 hash 值与数据共同传输至各数据源,各数据源获得数据并使用私钥解密得到 hash 值,并重新计算数据的 hash 值,判断传输计算的 hash 值与传输后重新计算的 hash 值是否相等。若二者相等,表明数据在传输过程中是安全与完整的,将数据存储至对应的数据源中;若二者不相等,表明数据在传输过程中被篡改,将数据从对应的数据源中删除。

(2)各数据源使用随机森林、朴素贝叶斯、神经网络、极端随机森林、GBDT (Gradient Boosting Decision Tree)和逻辑回归作为初始全局模型分别在各数据源的数据上进行训练,选择最优的作为初始全局模型,可以得到多个本地模型。

(3)各数据源的本地模型使用4种集成算法(stacking 集成算法、voting 集成算法、Adaboost 集成算法和平均法)和不集成方式分别整合为新的全局模型,经比较,stacking 模型与 Adaboost 模型

的效果最优,能满足要求。

(4)使用 256 B 的由 RSA 加密算法产生的私钥对新的全局模型进行加密,各数据源使用公钥进行解密,以此来保证全局模型的安全性。

2 相关知识

(1)联邦学习。

联邦学习是隐私保护下的算法优化可实现路径,同时也是保护数据安全中“数据孤岛”问题的解决方案^[7]。联邦学习允许从跨数据所有者分布的数据中构建联合模型,提供了跨企业的数据使用方式和模型构建蓝图,实现了各个企业的自有数据不出本地,只通过加密机制下的参数交换,不违反数据隐私法规地建立优化机器学习模型^[8]。

(2)stacking 集成算法。

stacking 集成算法是一种堆叠算法,第1步使用多个算法求出结果,再将结果作为特征输入到下一个算法中训练出最终的预测结果^[9],如图1所示。

(3)voting 集成算法。

voting 集成算法是通过多个模型和简单的统计量来进行组合预测^[10]。

(4)Adaboost 集成算法。

Adaboost 是一种迭代算法,其核心思想是针对同一个训练集训练不同的分类器,然后把这些弱分类器集合起来,构成一个更强的最终分类器^[11]。

(5)哈希算法。

哈希算法是将数据打乱混合,使用散列算法重新创建一个叫做散列值的指纹,通常用一个短的随机字母和数字组成的字符串表示散列值^[12]。

(6)RSA 加密算法。

RSA 加密算法是一种非对称加密算法,其公




Figure 1 stacking 集成过程

图1 stacking integration process

钥和私钥是一对大素数的函数,从一个公钥和密文恢复出明文的难度,等价于分解 2 个大素数之积^[13]。

(7) 随机森林。

随机森林是以决策树为基学习器构建集成的一种机器学习算法,是由很多决策树分类模型组成的组合分类模型,每个决策树分类模型都有一票投票权来选择最优的分类模型^[14]。

(8) 朴素贝叶斯。

朴素贝叶斯是一种基于贝叶斯决策理论的分类方法,是贝叶斯分类器的一种拓展与衍生^[15]。

(9) 神经网络。

神经网络是一种模仿动物神经网络行为特征进行分布式并行信息处理的算法模型,通过调整内部大量节点之间互相连接的关系达到信息处理的目的^[16]。

(10) 极端随机森林。

极端随机森林同样是一种多棵决策树集成的分类器,与随机森林分类器比较,区别是不采取 bootstrap 采样替换策略,而是直接采用原始训练样本,目的在于减少偏差;在每棵决策树的决策节点上,分裂测试的阈值是随机选择的^[17]。

(11) 逻辑回归。

logistic 回归是一种广义线性回归 (generalized linear model),模型形式为 $w'x + b$, logistic 回归函数 L 将 $y = w'x + b$ 对应一个隐状态 p , $p = L(w'x + b)$,根据 p 与 $1 - p$ 的大小决定因变量的值。如果 L 是 logistic 函数,就是 logistic 回归^[18]。

(12) GBDT。

GBDT 是一种用于回归的机器学习算法,该算法由多棵决策树组成,所有树的结论累加起来作为

最终答案^[19,20]。

3 联邦集成算法

3.1 算法描述

在联邦集成算法包括数据收集阶段与模型训练阶段。从数据收集阶段来说,首先是每个客户端的数据进行 hash 值计算,并将 hash 值与数据使用 RSA 加密算法产生的公钥加密后传输至各数据源;其次是各数据源使用私钥解密获取 hash 值与数据,各数据源需要重新计算数据的 hash 值;最后判断传输前计算的 hash 值与传输后重新计算的 hash 值,若不相等,则删除,若相等,则将数据存储至数据源内,并参与模型训练,具体过程如图 2 所示。

在模型训练阶段,首先是可信第三方使用由 RSA 加密算法产生的公钥加密初始化的随机森林、神经网络、朴素贝叶斯、极端随机森林、逻辑回归和 GBDT,并传输至各数据源;然后各数据源使用私钥解密,获取初始化的模型,并在各数据源上进行训练,根据其性能选择最优的作为初始全局模型,得到本地模型;最后使用 Adaboost、voting、stacking、平均法 4 种集成算法来整合本地模型参数,得到更新的全局模型,并不断迭代优化此阶段,以此提升全局模型的准确率,具体过程如图 3 所示。

算法流程如下所示:

Step 1 使用各客户端产生的数据计算其 hash 值,使用 RSA 加密算法所产生的公钥加密其 hash 值并将数据共同传输至各数据源;各数据源获得数据与使用私钥解密的 hash 值,并重新计算数据的 hash 值,判断传输前计算的 hash 值与传输




Figure 2 Data collection stage of the federated ensemble algorithm

图 2 联邦集成算法的数据收集阶段




Figure 3 Schematic diagram of the federated ensemble algorithm at the training model stage

图3 训练模型阶段的联邦集成算法示意图

后重新计算的 hash 值是否相等。若二者相等,将数据存储在数据源中并参与模型训练,若二者不相等,表明数据在传输过程中被篡改,删除该数据且不参与模型训练。

Step 2 对于联邦学习框架来说,初始化的全局模型决定着最终模型的上限,本文选择随机森林模型、神经网络模型、朴素贝叶斯模型、极端随机森林模型、逻辑回归和 GBDT 共 6 种模型作为初始化的全局模型,各数据源分别使用 6 种初始化的全局模型在本地进行训练,根据 6 种模型在各数据源上训练的得分情况进行选择。

Step 3 将最优的初始全局模型在各数据源上分别进行训练,并不断优化其对应的参数,建立各数据源所对应的本地模型。

Step 4 采用 voting 方法、Adaboost 方法、stacking 方法和平均法分别对各数据源所对应的本地模型进行集成,使更新的全局模型准确率满足要求。

Step 5 使用 RSA 加密算法产生 256 B 的密钥对,将公钥分发至各数据源,使用私钥加密新的全局模型传输至各数据源,各数据源使用公钥解密,并使用新的全局模型再次训练。

采用上述算法流程设计的算法如算法 1 所示。

算法 1 联邦集成算法

Input: dataset $\{D_i\}_{i=1}^n$, i represents the number of data sources, random forest: m_1 , naive Bayes: m_2 , neural network: m_3 , extremely random forest: m_4 , logistics regression: m_5 , GBDT: m_6 。

Output: hash encrypted dataset $\{D'_i\}_{i=1}^n$; RSA generate key pair P_i, p_i ; original global model H , local model h_i , up-

dated global model h 。

1. //(1)Data collection stage

2. for $i=0$ to n

3. $D'_i = E_hash(D_i)$;

4. return D'_i

5. end for

6. //(2)Generate secret key

7. for $i=0$ to n

8. Various data sources: $P_i = G_{public} _RSA(x)$, $p_i = G_{private} _RSA(x)$; // x represents a random number

9. end for

10. //(3)Validation dataset

11. for $i=0$ to n

12. Clients: $D'_i = E_P_i(D'_i)$

13. Various data sources: $D'_i = D_p_i(D'_i)$ and recalculate: $D''_i = E_hash(D_i)$;

14. if $D'_i \neq D''_i$

15. delete D_i ;

16. exit;

17. else

18. send D_i to various data sources;

19. end for

20. //(4)Model training stage

21. Trusted third party: $y_1, y_2, y_3, y_4, y_5, y_6 = E_RSA(m_1, m_2, m_3, m_4, m_5, m_6)$ send to various data sources;

22. Various data sources: $m_1, m_2, m_3, m_4, m_5, m_6 = D_RSA(y_1, y_2, y_3, y_4, y_5, y_6)$;

23. $s_1(D_i), s_2(D_i), s_3(D_i), s_4(D_i), s_5(D_i), s_6(D_i) = m_1_train(D_i), m_2_train(D_i), m_3_train(D_i), m_4_train(D_i), m_5_train(D_i), m_6_train(D_i)$;

24. $H = voting\{max_score(s_1(D_i), s_2(D_i), s_3(D_i), s_4$

$$(D_i), s_5(D_i), s_6(D_i))_{i=1}^n;$$

25. for $i=1$ to n

26. $\{h_i\}_{i=1}^n = \{train(H, D_i)\}_{i=1}^n;$

27. Trusted third party: $h = stacking(\{h_i\}_{i=1}^n), h =$
 $Adaboost(\{h_i\}_{i=1}^n)$ and $h = voting(\{h_i\}_{i=1}^n), h =$
 $average(\{h_i\}_{i=1}^n);$

28. end for

3.2 性能分析

本文提出的联邦集成算法能够在保证模型准确率的前提下,提升数据与模型的安全性。

3.2.1 算法的复杂度分析

联邦集成算法的复杂度为哈希算法的复杂度、RSA 加密算法产生的复杂度、选择最优的初始化全局模型并产生子模型的复杂度和将多个本地模型集成为最终的全局模型的复杂度之和。即时间复杂度为 $O(M(mn \log n) + M^4)$, 其中, n 代表样本数, m 表示特征数, M 表示有 M 棵树来投票。事实上,采用联邦学习框架和 stacking 集成算法必然会造成此算法的时间复杂度和空间复杂度均高于传统的数据融合算法,但兼顾了模型准确率和数据与模型的安全性^[21]。

3.2.2 算法的安全性分析

该算法使用联邦学习框架与集成学习的思想,从数据层面上,使用 RSA 加密算法对每个客户端的数据进行 hash 计算,并将 hash 值与数据共同传输至各数据源,各数据源重新计算其 hash 值,可保证数据在收集阶段的安全性与完整性。从模型层面上:(1)采用 RSA 非对称加密算法,采用 256 B 的密钥来加密全局模型,并将加密的全局模型分发至各数据源,各数据源根据新的全局模型再次进行训练来优化全局模型;(2)该算法是在联邦学习的框架下实现的,各数据源的数据存储在本地,消除了因数据传输带来的风险,提升了模型与数据的安全性。

4 实验与结果分析

4.1 实验参数设置

本文设计的算法由 Python 语言和 Pycharm 集成软件开发实现。实验硬件环境为: Intel(R) Core i5-4200M CPU 2.50 GHz 处理器,内存 8 GB; 操作系统为 Windows 10。在实验数据方面,采用从 <http://sofasofa.io/competition.php?id=2> 下载的数据集,该数据集有 15.6 MB。

4.2 实验数据分析

各客户端使用 RSA 加密算法产生的公钥来加密由 hash 算法计算的数据 hash 值,并与数据共同传输至各数据源,各数据源使用私钥解密,且重新计算数据的 hash 值,判断数据经过传输的 hash 值与传输前的 hash 值是否相等,将 hash 值相等的数据存储至各数据源内,可保证数据在收集阶段的安全性与完整性。

模型训练阶段分为 2 部分,第 1 部分:可信第三方使用公钥加密 6 种类型的初始模型,并传输至各数据源;将集成后更新的全局模型使用公钥加密传输至各数据源,各数据源使用私钥解密进行训练来优化全局模型。第 2 部分:各数据源使用私钥解密后,获取 6 种初始模型,使用 6 种初始模型在各数据源上进行训练,可以得到多个本地模型,同时选择最优的作为初始全局模型,然后使用集成算法进行集成,获得更新的全局模型准确率均值。

为保证全局模型分发至数据源上的安全性,采用 RSA 加密算法随机产生 256 B 的密钥(图 4 和图 5 为公私钥的变化图),使用私钥加密全局模型,将公钥广播至各数据源;各数据源使用公钥解密全局模型进行训练,以优化全局模型。

公钥

```

MIIBIJANBGKQHKIG9W0BAQEFAA0CAQ8AMIIBCGKCAQEA
MXG32RH6YUQC8BCVXEIYcuq@J+phpbgwplwswoojynucgz8
0czxsbsmvve8Jqodz49w2mgeblk2j9rfpiwl2ftjd5hmXim9p8b
8q+FTLUMHK0ANCHVUAY01ENGCSYCHDPVGRCCFFWCR8ASZ
HDD4AYXHJHWAMIDWZNU56kfask+QEPW2HYVQCXZX4K8E
K0I6Y93LWDSH9X6IJK@JHKQGQFCUPXZHP9cxuhxcepi9Jgdr
1ghl0elpxiycf75JYMUASXAZ7KKR7ERFVREBRN3HWHFSEHYQ
IDAQAB

miiibijanbgkqhkgig9wobaqefaa0caq8amiibcgkcaqea7hsm8
adbnpkn7gjnlds73GFXIUTZUYQVC329wqxfig5x1x0bv61g
btvtqfsn1c9f9lwxvnm513gunagixS1lpezl8qo+0JF1MZTX+6
d1zdabNOEDRIXA+yepmfcM+SPXY15METHXDAPWOMDP
ekq1igjelktuefp0xpjhi1jgveo4vd+tuu8fhtevqcbdeq+CG2H
XIGCDNR+8d+QTBNSYNOMPRDYWH7WPAKTH9VINFIRU0
CBTDOTKTNKL1VVQS7TXCRC4XMDXPSV4PVJIAYPuzsssho
w1rspkthivqegx7higfs9kqvzwnslho7l6k11gqkacm3gqhic1
WIDAQAB

```

Figure 4 Change of public key generated by RSA encryption algorithm

图 4 采用 RSA 加密算法产生的公钥变化图

在联邦学习的框架下,初始全局模型的优劣决定着模型的上限,本文选择 6 种初始模型,分别为:随机森林、朴素贝叶斯、极端随机森林、神经网络、逻辑回归和 GBDT,且使用平均值与标准差作为衡量初始全局模型优劣的标准,6 种初始模型的性能如表 1 所示。



Figure 5 Change of private key generated by RSA encryption algorithm

图 5 采用 RSA 加密算法产生的私钥变化图

Table 1 Performance of the initial model

表 1 初始模型性能

初始模型	均值 (means)	标准差 (variance)
随机森林	0.918 785 361	0.002 599 735
朴素贝叶斯	0.821 916 254	0.039 271 756
极端随机森林	0.920 274 892	0.003 058 123
神经网络	0.909 995 206	0.002 690 737
逻辑回归	0.878 513 613	0.000 000 713
GBDT	0.910 805 263	0.002 630 231

从表 1 中可以看到, 准确率均值最高的依次是极端随机森林、随机森林、GBDT、神经网络、逻辑回归和朴素贝叶斯, 标准差从小到大的顺序依次是逻辑回归、随机森林、GBDT、神经网络、极端随机森林和朴素贝叶斯。随机森林与极端随机森林的准确率相差不多, 但标准差却相差很大, 故综合考虑性能从高到低的排名是随机森林、极端随机森

林、GBDT、神经网络、逻辑回归和朴素贝叶斯。

根据 6 种初始全局模型在各数据源上的表现, 本文依次选用随机森林、极端随机森林、GBDT、神经网络、逻辑回归和朴素贝叶斯作为初始全局模型。而对于多个本地模型采用 stacking 集成算法、voting 集成算法、Adaboost 集成算法和平均法依次对多个本地模型进行集成, 得到 4 种集成算法集成的新全局模型的准确率。

图 6 表示初始全局模型选用随机森林时使用 4 种集成算法与传统整合多方数据集中训练的方法^[22, 23]在各数据源上训练的准确率变化情况, 本文将迭代 100 次的平均值作为训练结果的数值, 表 2 为随机森林使用 4 种集成算法与传统整合多方数据集中训练的方法的性能。




Figure 6 Accuracy changes in the training of four ensemble algorithms and traditional method on various data sources

图 6 随机森林使用 4 种集成算法与传统方法训练的准确率变化情况

Table 2 Performance of random forest using four ensemble algorithms and traditional method

表 2 随机森林使用 4 种集成算法与传统方法的性能

算法	均值 (means)	标准差 (variance)
stacking	0.924 964 5	0.000 297 514
voting	0.921 879 0	0.000 480 114
Adaboost	0.925 044 5	0.000 293 334
平均法	0.923 712 0	0.000 359 000
传统方法	0.925 206 5	0.000 305 668

从表 2 可以得到, 准确率均值从高到低依次是传统整合多方数据集中训练的方法、Adaboost 集成算法、stacking 集成算法、平均法和 voting 集成算法, 标准差从小到大的顺序依次是 Adaboost 集成算法、stacking 集成算法、传统整合多方数据集

中训练的方法、平均法和 voting 集成算法,其中 Adaboost 集成算法与 stacking 集成算法比传统方法的准确率均值下降约 0.2%,传统整合数据方法的准确率均值为 92.52%,Adaboost 集成算法的准确率均值为 92.50%,stacking 集成算法的准确率均值为 92.49%,且从标准差来看,模型最稳定的是 Adaboost 集成算法与 stacking 算法(标准差越小模型越稳定)。

极端随机森林为初始全局模型的准确率高随机森林,但标准差较大,说明模型的稳定性差,故综合考虑其性能仅次于随机森林。

图 7 表示初始全局模型选用极端随机森林使用 4 种集成算法与传统整合多方数据集中训练的方法在各数据源上的训练情况,本文将迭代 100 次的平均值作为训练结果的数值。表 3 为随机森林使用 4 种集成算法与传统整合数据方法的性能。




Figure 7 Accuracy changes of extreme random forest training using four integrated algorithms and traditional method

图 7 极端随机森林使用 4 种集成算法与传统方法训练的准确率变化情况

Table 3 Performance of extreme random forest using four ensemble algorithms and traditional method

表 3 极端随机森林使用 4 种集成算法与传统方法的性能

算法	均值(means)	标准差(variance)
stacking	0.923 993 5	0.000 174 306
voting	0.920 354 5	0.000 241 774
Adaboost	0.923 839 5	0.000 093 620
平均法	0.921 924 0	0.000 183 000
传统方法	0.924 021 5	0.000 190 559

从表 3 可以得到,准确率均值从高到低依次是

传统整合多方数据集中训练的方法、stacking 集成算法、Adaboost 集成算法、平均法和 voting 集成算法,标准差从小到大的顺序依次是 Adaboost 集成算法、stacking 集成算法、平均法、传统整合多方数据集中训练的方法和 voting 集成算法,其中 stacking 集成算法与传统整合多方数据集中训练的方法准确率均值相比,准确率均值下降不到 0.1%,Adaboost 集成算法与传统整合多方数据集中训练方法相比,准确率均值下降不到 0.2%,传统整合多方数据集中训练方法的准确率为 92.402%,stacking 集成算法的准确率为 92.399%,Adaboost 集成算法的准确率为 92.384%,且模型最稳定的是 Adaboost 集成算法与 stacking 算法。

GBDT 为初始全局模型的准确率低于随机森林与极端随机森林,其标准差高于随机森林,低于极端随机森林,说明模型的稳定性较差,故综合考虑其性能次于随机森林与极端随机森林。

图 8 表示初始全局模型为 GBDT 时使用 4 种集成算法与传统整合多方数据集中训练的方法在各数据源上训练的准确率变化情况,本文将迭代 100 次的平均值作为其训练结果的数值。表 4 为 GBDT 使用 4 种集成算法与传统整合数据方法的性能。




Figure 8 Accuracy changes of GBDT training using four integrated algorithms and traditional method

图 8 GBDT 使用 4 种集成算法与传统方法训练的准确率变化

从表 4 可以得到,准确率均从高到低依次是 Adaboost 集成算法、voting 集成算法、stacking 集成算法、传统整合多方数据集中训练的方法和平均法,标准差从小到大的顺序依次是平均法、voting

Table 4 Performance of GBDT using four ensemble algorithms and traditional method

表 4 GBDT 使用 4 种集成算法与传统方法的性能

算法	均值(means)	方差(variance)
stacking	0.921 736	2.28×10^{-5}
voting	0.923 000	1.34×10^{-15}
Adaboost	0.926 765	1.25227×10^{-4}
平均法	0.911 700	1.12×10^{-16}
传统方法	0.921 728	2.49×10^{-5}

集成算法、stacking 集成算法、传统整合多方数据集中训练的方法和 Adaboost 集成算法,其中 Adaboost 集成算法、voting 集成算法、stacking 集成算法的准确率均高于传统整合多方数据集中训练的方法,Adaboost 集成算法的准确率均值 92.676 5%,voting 集成算法的准确率均值为 92.3%,stacking 集成算法的准确率均值为 92.173 6%,传统整合多方数据集中训练的方法的准确率均值为 92.172 8%。

神经网络为初始全局模型的准确率低于随机森林、极端随机森林和 GBDT,其标准差高于随机森林与 GBDT,低于极端随机森林,说明模型的稳定性较差,故综合考虑其性能次于随机森林、极端随机森林和 GBDT。由于不同参数的神经网络无法使用 Adaboost 进行集成,故采用 stacking 集成算法、voting 集成算法和平均法来整合不同参数的神经网络。

图 9 表示初始全局模型选用神经网络时使用 3 种集成算法与传统整合多方数据集中训练的方法在各数据源上训练的准确率变化情况,本文将迭代 100 次的平均值作为其训练结果的数值。




Figure 9 Accuracy changes of neural network training using three ensemble algorithms and traditional method

图 9 神经网络使用 3 种集成算法与传统方法训练的准确率变化

表 5 为神经网络使用 3 种集成算法与传统整合数据方法的性能。

Table 5 Performance of neural network using three ensemble algorithms and traditional method

表 5 神经网络使用 3 种集成算法与传统方法的性能

算法	均值(means)	标准差(variance)
stacking	0.912 661 5	0.007 211 736
voting	0.908 190 5	0.017 024 848
平均法	0.913 697 0	0.001 624 000
传统方法	0.906 919 0	0.021 819 658

从表 5 可以得到,准确率均值从高到低依次是平均法、stacking 集成算法、voting 集成算法和传统整合多方数据集中训练的方法,标准差从小到大的顺序依次是平均法、stacking 集成算法、voting 集成算法和传统整合多方数据集中训练的方法,其中平均法的准确率均值为 91.3697%,stacking 集成算法的准确率均值为 91.266%,voting 集成算法的准确率均值为 90.819 1%,传统整合多方数据集中训练的方法准确率均值为 90.6919%。

逻辑回归为初始全局模型的准确率低于随机森林、极端随机森林、GBDT 和神经网络,其标准差在 6 种模型中最低,说明模型的稳定性较好,故综合考虑其性能次于随机森林、极端随机森林、GBDT 和神经网络。

图 10 表示初始全局模型选用逻辑回归时使用 4 种集成算法与传统整合多方数据集中训练的方法在各数据源上训练的准确率变化情况,将迭代 100 次的平均值作为训练结果的数值。表 6 为逻辑回归使用 4 种集成算法与传统整合多方数据集中训练的方法的性能。




Figure 10 Accuracy changes of logistic regression using four kinds of integrated algorithms and traditional method

图 10 逻辑回归使用 4 种集成算法与传统方法训练的准确率变化

从表 6 可以得到,准确率均值从高到低依次是 stacking 集成算法、传统整合多方数据集中训练的方法、voting 集成算法、平均法和 Adaboost 集成算法,标准差从小到大的顺序依次是平均法、voting 集成算法、传统整合多方数据集中训练的方法、

Adaboost 集成算法和 stacking 集成算法,其中 stacking 集成算法的准确率均值为 89.76%,传统整合多方数据集中训练的方法准确率均值为 88.955%,voting 集成算法的准确率均值为 88.88%,平均法的准确率均值为 88.705%,Ada-boost 集成算法的准确率均值为 86.81%。

Table 6 Performance of logistic regression using four integrated algorithms and traditional method

表 6 逻辑回归使用 4 种集成算法与传统方法的性能

算法	均值(means)	标准差(variance)
stacking	0.897 60	1.6×10^{-15}
voting	0.888 00	1.1×10^{-15}
Adaboost	0.868 10	1.2×10^{-15}
平均法	0.887 05	1.1×10^{-15}
传统方法	0.889 55	1.1×10^{-15}

朴素贝叶斯为初始全局模型的准确率低于随机森林、极端随机森林、GBDT、神经网络和逻辑回归,其标准差高于随机森林、极端随机森林、GBDT 和神经网络,说明模型的稳定性差,故综合考虑其性能次于随机森林、极端随机森林、GBDT 和神经网络。

图 11 表示初始全局模型选用朴素贝叶斯时使用 4 种集成算法与传统整合多方数据集中训练的方法在各数据源上训练的准确率变化情况,将迭代 100 次的平均值作为训练结果的数值。表 7 为朴素贝叶斯使用 4 种集成算法与传统整合数据集中方法的性能。




Figure 11 Changes of naive Bayes training using four ensemble algorithms and traditional methods

图 11 朴素贝叶斯使用 4 种集成算法与传统方法训练的准确率变化

Table 7 Naive Bayes performance using four ensemble algorithms and traditional method

表 7 朴素贝叶斯使用 4 种集成算法与传统方法的性能

算法	均值(means)	标准差(variance)
stacking	0.859 00	$3.330\ 67\times10^{-16}$
voting	0.866 75	$1.110\ 22\times10^{-16}$
Adaboost	0.845 75	$4.440\ 89\times10^{-16}$
平均法	0.866 55	3.35×10^{-16}
传统方法	0.866 20	$1.221\ 25\times10^{-15}$

对于传统处理多源数据的做法是将各数据源的数据整合在数据中心,并使用不同的初始化模型在数据中心上进行训练,获取多方均满意的模型。图 12 为随机森林、极端随机森林、神经网络、朴素贝叶斯、GBDT、逻辑回归 6 种模型使用传统方法训练的情况。




Figure 12 Six models were trained using traditional method

图 12 6 种模型使用传统方法训练的准确率情况

从图 12 中可以看到,随机森林的准确率最高,剩下的依次是极端随机森林、GBDT、神经网络(多数情况下优于朴素贝叶斯)、逻辑回归和朴素贝叶斯(只有少数情况下优于神经网络)。表 8 是不同类型的模型在数据中心(多源数据整合后的存储处)的性能。

Table 8 Performance of different types of models in the data center

表 8 不同类型的模型在数据中心的性能

算法	均值(means)	标准差(variance)
随机森林	0.925 206 5	0.000 305 668
朴素贝叶斯	0.866 200 0	$1.221\ 25\times10^{-15}$
极端随机森林	0.924 021 5	0.000 190 559
神经网络	0.906 919 0	0.021 819 658
GBDT	0.921 730 0	2.5×10^{-5}
逻辑回归	0.889 550 0	1.1×10^{-5}

4.3 实验小结

联邦集成学习算法常用的初始全局模型为随机森林、朴素贝叶斯、神经网络、极端随机森林、逻辑回归和 GBDT,分别在各数据源的数据上进行训练,得到随机森林的准确度与极端随机森林的准确率最高,但极端随机森林的模型稳定性很差,所以综合考虑选择随机森林作为最优的初始全局模型,

可以得到 4 种集成算法与传统整合多方数据集中训练的方法的结果除 voting 外,其他的 3 个均相差不多,但相比之下传统整合多方数据集中训练的方法稳定性较差,但可以使模型与数据的安全性得到很大的提升。所以,将 Adaboost 集成算法与 stacking 集成算法作为整合多个本地模型的集成算法。文献[24]将 stacking 集成算法与 Adaboost 集成算法、voting 集成算法进行比较,结果表明 stacking 集成算法泛化能力强且适用于大数据样本。所以,对于中小数据样本而言,采用 Adaboost 集成算法来实现本文提出的联邦集成算法;对于大数据样本而言,采用 stacking 集成算法来实现本文提出的联邦集成算法。

5 结束语

本文在基于联邦学习和集成学习的思想下提出的联邦集成学习算法,在集成算法的过程中,使数据以及模型的安全性得到明显的提升,同时保持了全局模型的可用性。本文算法与传统的整合多方数据集中训练的方法相比,主要还有 3 点需要改进:(1)数据融合时的时间复杂度与空间复杂度较高。(2)没有考虑传输协议,即初始全局模型传输至各数据源和各数据源训练的本地模型传输至可信第三方两部分传输协议的安全性问题。(3)初始全局模型以及集成方法选择得不全面,只选择了联邦学习常用的全局模型以及常用的集成方法。实验表明,本文算法在数据安全性以及模型准确性和安全性上都有了很大的提升。未来将继续研究联邦集成学习算法中的模型在传输过程中的安全性问题。

参考文献:

- [1] McMahan H B, Moore E, Ramage, et al. Communication-efficient learning of deep networks from decentralized data [C]//Proc of the 20th International Conference on Artificial Intelligence and Statistics, 2017: 1-11.
- [2] Konecny J, McMahan H B, Yu F X, et al. Federated learning: Strategies for improving communication efficiency [C]//Proc of the 30th Annual Conference on Neural Information Processing Systems, 2016: 1-10.
- [3] Yang Qiang. Challenges of GDPR to AI and countermeasures based on federal transfer learning[J]. Communications of Chinese Association for Artificial Intelligence, 2018(8): 1-8. (in Chinese)
- [4] Yang Q, Liu Y, Chen T J, et al. Federated machine learning: Concept and applications[J]. ACM Transactions on Intelligent Systems and Technology, 2019, 10(2): 1-19.
- [5] Wang S, Tuor T, Salonidis T, et al. Adaptive federated learning in resource constrained edge computing systems[J]. IEEE Journal on Selected Areas in Communications, 2019, 37(6): 1205-1221.
- [6] Liu Y, Liu Y T, Liu Z J, et al. Federated forest[J]. IEEE Transactions on Big Data, 2020; doi:10.1109/DATA.2020.2992755.
- [7] Sharma S, Chen K. Poster: Privacy-preserving boosting with random linear classifiers[C]//Proc of the 2018 ACM SIGSAC Conference on Computer and Communications Security, 2018: 1-13.
- [8] Sun C, Shrivastava A, Singh S, et al. Revisiting unreasonable effectiveness of data in deep learning era[C]//Proc of 2017 IEEE International Conference on Computer Vision, 2017: 843-852.
- [9] Kim H, Park J, Bennis M, et al. On-device federated learning via blockchain and its latency analysis [J]. arXiv: 1808.03949, 2018.
- [10] Li S Y, Cheng Y, Liu Y, et al. Abnormal client behavior detection in federated learning [J]. arXiv: 1910.09933v2, 2019.
- [11] Zhun L G, Liu Z J, Hong S. Deep leakage from gradients [J]. arXiv: 1906.08935v1, 2019.
- [12] Chen Yu-sheng, Yang Yan-hun, Lin Meng, et al. Fault diagnosis technology of nuclear power plant based on deep learning neural network [J]. Journal of Shanghai Jiao Tong University, 2018, 52(S1): 58-61. (in Chinese)
- [13] Gao H H, Huang W Q, Yang X X. Applying probabilistic model checking to path planning in an intelligent transportation system using mobility trajectories and their statistical data[J]. Intelligent Automation and Soft Computing (Auto-soft), 2019, 25(3): 547-559.
- [14] Gao H H, Huang W Q, Duan Y C, et al. Research on cost-driven services composition in an uncertain environment[J]. Journal of Internet Technology (JIT), 2019, 20(3): 755-769.
- [15] Preuveneers D, Rimmer V, Tsingenopoulos I, et al. Chained anomaly detection models for federated learning: An intrusion detection case study[J]. Applied Sciences, 2018, 8(12): 2663.
- [16] Brisimi T S, Chen R, Mela T, et al. Federated learning of predictive models from federated electronic health records [J]. International Journal of Medical Informatics, 2018, 112: 59-67.
- [17] Zhang W S, Zhang Y J, Zhai J, et al. Multi-source data fusion using deep learning for smart refrigerators[J]. Computers in Industry, 2018, 95: 15-21.
- [18] Lee J, Wang F, Sun J M, et al. Privacy-preserving patient similarity learning in a federated environment: Development and analysis[J]. JMIR Medical Informatics, 2018, 6(2): e20.
- [19] Shen G J, Han X, Zhou J J, et al. Research on intelligent analysis and depth fusion of multi-source traffic data[J].

IEEE Access, 2018, 6: 59329-59335.

- [20] Liu J, Li T R, Xie P, et al. Urban big data fusion based on deep learning: An overview[J]. Information Fusion, 2020, 53: 123-133.
- [21] Gai Zhi-hao. Support vector machine model based on multi-source data fusion[D]. Xiamen: Xiamen University, 2019. (in Chinese)
- [22] Fang Kuang-nan, Zhao Meng-luan. Research on personal credit scoring based on multi-source data fusion[J]. Statistical Research, 2018, 35(12): 92-101. (in Chinese)
- [23] Chen Jing-ran, Dong Xin-yang, Zong Chuan-yu, et al. Marine multimodal data genealogy prototype system[J]. Journal of Computer Research and Development, 2015, 52(S1): 118-122. (in Chinese)
- [24] Lu Ying, Zheng Shao-zhi. A comparative study of stacking learning and general ensemble methods[J]. China Science-paper, 2018, 11(4): 372-379. (in Chinese)

附中文参考文献:

- [3] 杨强. GDPR 对 AI 的挑战和基于联邦迁移学习的对策[J]. 中国人工智能学会通讯, 2018(8): 1-8.
- [12] 陈玉昇, 杨燕华, 林萌, 等. 基于深度学习神经网络的核电厂故障诊断技术[J]. 上海交通大学学报, 2018, 52(S1): 58-61.
- [21] 盖志浩. 基于多源数据融合的支持向量机模型[D]. 厦门: 厦门大学, 2019.
- [22] 方匡南, 赵梦峦. 基于多源数据融合的个人信用评分研究[J]. 统计研究, 2018, 35(12): 92-101.
- [23] 陈井冉, 董鑫洋, 宗传玉, 等. 海洋多模态数据世系原型系统[J]. 计算机研究与发展, 2015, 52(S1): 118-122.
- [24] 鲁莹, 郑少智. Stacking 学习与一般集成方法的比较研究[J]. 中国科技论文在线, 2018, 11(4): 372-379.

作者简介:



罗长银(1994-), 男, 陕西安康人, 硕士生, CCF 会员(B5216G), 研究方向为数据安全。E-mail: 1394301218@qq.com

LUO Chang-yin, born in 1994, MS candidate, CCF member (B5216G), his research interest includes data security.



陈学斌(1970-), 男, 河北唐山人, 博士, 教授, CCF 高级会员(13654S), 研究方向为数据安全、物联网安全和网络安全。E-mail: chxb@qq.com

CHEN Xue-bin, born in 1970, PhD, professor, CCF senior member (13654S), his research interests include data security, IoT security, and network security.



刘洋(2000-), 男, 河北保定人, 研究方向为机器学习。E-mail: 2471001205@qq.com

LIU Yang, born in 2000, his research interest includes machine learning.



张淑芬(1972-), 女, 河北唐山人, 博士, 教授, CCF 会员(14427M), 研究方向为数据安全。E-mail: hblgzhsf@qq.com

ZHANG Shu-fen, born in 1972, PhD, professor, CCF member (14427M), her research interest includes data security.